



Departamento de Matemática
Mestrado em Engenharia Matemática

Medidas de Distorção de Shaun S. Wang e a sua Aplicação em Seguradoras

Teoria de Risco - M4059

Beatriz Carvalho (202107558)
Rita Chamusca (202106828)
João Amaral (202105032)

10 de dezembro de 2024

Índice

1	Introdução	3
2	Medidas de Distorção	4
2.1	O que é uma medida de distorção?	4
2.2	Propriedades Ótimas de Funções de Distorção	5
3	Funções de Distorção de Wang	6
3.1	PH-transform	6
3.2	Função de Distorção de Wang	7
3.2.1	Algumas propriedades da função de Wang	8
3.3	Exemplos	9
3.3.1	Exemplo 3.1	10
3.3.2	Exemplo 3.2	10
4	Análise de perdas de uma seguradora	12
4.1	Análise de Dados e Transformação de Wang	13
4.2	Análise de Resultados	14
5	Conclusão	16

1 Introdução

As medidas de Risco são um pilar fundamental na gestão de risco, tanto numa perspectiva de investimentos, como numa perspectiva de seguradoras. São o que avalia e permite mitigar o risco, o que ajuda na tomada de decisões sobre, por exemplo, carteiras de investimento, ou sobre apólices de seguro. São úteis na medida em que facilitam a tomada de decisões e auxiliam a que se minimize perdas, e que se maximize retornos.

A gestão destas situações é algo vital para o seu desenvolvimento sustentável, pelo que são algo de elevado interesse teórico e prático.

Shaun Shuxun Wang, atualmente professor na Universidade de Ciências e Tecnologias do Sul da China, é conhecido pelo seu trabalho em modelação de risco. O seu trabalho, e invenção, mais reconhecido é a "Transformada de Wang", uma fórmula matemática para atribuir preços a riscos. Neste trabalho, vamos explorar duas das suas mais reconhecidas transformadas: Os modelos de risco proporcionais (PH transform), e as suas medidas de distorção. Sendo algo relativamente recente (1995 e 2000), é algo em constante evolução, e um ponto de referencia para qualquer pessoa interessada em teoria de risco.

Os artigos correspondentes a estas transformadas tem mais de 1300 citações em conjunto, o que revela que são de elevado interesse para o campo das medidas de risco.

2 Medidas de Distorção

2.1 O que é uma medida de distorção?

Uma medida de distorção é uma função utilizada na teoria de Risco e em finanças, que serve para transformar distribuições de probabilidade, de forma a que se reflita melhor a aversão ao risco. Estas medidas são muito úteis pois levam em conta, não só o valor esperado, mas também a percepção do risco. Assim uma medida de distorção simplesmente aplica uma transformação às probabilidades, distorcendo os valores mais extremos de forma a aumentar a percepção do risco desses eventos.

Seja X uma variável aleatória com função de distribuição:

$$F_X(x) = P(X \leq x)$$

Definimos a função de sobrevivência como:

$$S_X(x) = 1 - F_X(x) = P(X > x)$$

E temos que:

$$\mathbf{E}[\mathbf{X}] = \int_{-\infty}^0 S_X(x) - 1 \, dx + \int_0^{+\infty} S_X(x) \, dx$$

No caso que X é uma Variável Aleatória não negativa temos apenas o integral de 0 a infinito.

Por fim precisamos também definir o que é uma Variável Aleatória por camadas, que são muito úteis na área das finanças e da teoria de risco. Seja $X(a, a + m]$ a *v.a.*:

$$X(a, a + m] = \begin{cases} 0 & \text{se } 0 \leq X < a \\ X - a & \text{se } a \leq X < a + m \\ m & \text{se } X \geq a + m \end{cases}$$

Onde a é chamado de retenção ou dedutível e m é o limite. É fácil de ver que a sua função sobrevivência e o seu valor esperado são, respetivamente:

$$S_{X(a, a+m]}(y) = \begin{cases} S_X(a + y) & \text{se } 0 \leq y < m \\ 0 & \text{se } y \geq m \end{cases}$$

$$\mathbf{E}[X] = \int_0^{+\infty} S_{X(a, a+m]}(y) \, dy = \int_a^{a+m} S_X(x) \, dx$$

Seja agora $g : [0, 1] \rightarrow [0, 1]$, uma função crescente com $g(0) = 0$ e $g(1) = 1$. Assim g é chamada de função de distorção. Esta função vai transformar a distribuição de $S_X(x)$, numa nova distribuição $g[S_X(x)]$. O valor esperado da distribuição transformada $H_g(X)$, representa o prémio ajustado ao risco.

$$H_g(X) = \int_0^{+\infty} g[S_X(x)] dx$$

Tambem é obvio que:

$$H_g(X(a, a + m)) = \int_0^{+\infty} g[S_{X(a, a+m)}(y)] dy = \int_a^{a+m} g[S_X(x)] dx$$

2.2 Propriedades Ótimas de Funções de Distorção

Através de [2], foi mostrado que uma função ¹ de distorção, deve cumprir os seguintes requisitos de modo a modelar melhor os eventos pretendidos, como por exemplo, Variáveis Aleatórias por camadas.

- $0 < g(u) < 1$, $g(0) = 0$ e $g(1) = 1$. Estas condições asseguram que para cada valor de x , $g[S_X(x)]$ define uma probabilidade válida e que eventos com probabilidade diferentes de zero continuarão a ter probabilidade diferente de zero mesmo depois de se aplicar o operador de distorção g ;
- $g(u)$ é uma função crescente (onde existe, $g'(u) \geq 0$). Isto serve para assegurar que a distorção de probabilidade $g[S_X(x)]$ define outra distribuição e que o prémio ajustado ao risco da camada diminui à medida que a camada aumenta, dado um limite fixo.
- $g(u)$ é concava (onde existe, $g''(u) \leq 0$). Isto serve para assegurar que a carga de risco não é negativa para cada risco ou camada, e que a carga de risco relativo aumenta à medida que o ponto de fixação (retenção) aumenta até um limite fixo.
- $g'(0) = +\infty$. Isto é necessário para assegurar uma carga relativa ilimitada em camadas extremamente elevadas. ²

¹Muitas vezes será utilizado a palavra operador, embora sejam conceitos diferentes, vamos neste trabalho usar ambos os termos para dar uma maior simplicidade

²As noções de carga relativa, carga de risco, bem como prémio do risco ajustado serão abordadas com mais detalhe na secção 3.1

3 Funções de Distorção de Wang

Vamos agora nesta secção e nas restantes, aprofundar um pouco sobre as funções de distorção de S. Wang, nomeadamente a *PH-transform* apresentada em [1] e a *Função de Distorção de Wang*, apresentada em [4]. Vamos mostrar que cumprem as propriedades apresentadas em 2.2 e de seguida dar exemplos teóricos das suas aplicações.

3.1 PH-transform

A função *PH* também conhecida como "Proportional Hazards" é definida por:

$$g(u) = u^r, 0 \leq r \leq 1$$

Esta função de distorção quando aplicada a uma função de sobrevivência, com um r nas condições acima, vai distorcer os valores, de modo a que valores mais elevados tenham uma maior percepção, refletindo assim a aversão ao risco.

Vamos agora ver que g cumpre os requisitos de uma boa função de distorção:

- Os limites são:

$$g(0) = \lim_{u \rightarrow 0^+} g(u) = (0^+)^r = 0 \text{ se } u \neq 0$$

$$\text{Se } u = 0, g(u) = 0 \implies g(0) = 0$$

$$g(1) = \lim_{u \rightarrow 1^-} g(u) = 1^r = 1$$

- A primeira derivada é:

$$\frac{d(g(u))}{du} = ru^{r-1}$$

Como $r \in [0, 1]$ e o domínio de g é $[0, 1]$ então $g'(x) \geq 0$.

Em particular:

$$g'(0) = \lim_{u \rightarrow 0^+} g'(u) = +\infty$$

- A segunda derivada é:

$$\frac{d^2(g(u))}{du^2} = r(r-1)u^{r-2}$$

Que é sempre negativo nas condições dadas.

Embora seja uma função de distorção bastante simples, ela modela bastante bem vários conceitos nas atividades das finanças e das seguradoras. Contudo, ela ainda não cumpre todos os requisitos para ser ótima, dado que, por exemplo, falha ao incorporar a fórmula de Black-Scholes, que é bastante utilizada no mundo financeiro. Outra falha desta função é que quando as camadas começam a ficar muito altas a carga relativa também aumenta muito depressa, o que não é desejado.

3.2 Função de Distorção de Wang

Vamos começar por relembrar algumas coisas úteis na definição desta função.

Seja $\Phi(x)$ a função de distribuição de uma Normal com média 0 e desvio-padrão de 1, e seja $f(x)$ a sua função densidade de probabilidade.

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \text{ com } -\infty < x < +\infty$$

Seja agora $x = \Phi^{-1}(u)$, ou seja x denota o quantil na distribuição normal standard.

Podemos agora definir a função de distorção de Wang:

$$g_\alpha(u) = \Phi(\Phi^{-1}(u) + \alpha)$$

Onde α é um número real.

Vamos verificar agora que este operador cumpre todos os requisitos definidos em **2.2**.

Vejamos:

- Os limites são:

$$g_\alpha(0) = \lim_{u \rightarrow 0^+} g_\alpha(u) = \lim_{u \rightarrow 0^+} [\Phi(\Phi^{-1}(u) + \alpha)]$$

Temos que ³ $\Phi(-\infty) = 0$ e que $-\infty + \alpha = -\infty$. Então:

$$g_\alpha(0) = \Phi(-\infty) = 0$$

Analogamente, temos que:

$$g_\alpha(1) = \lim_{u \rightarrow 1^-} g_\alpha(u) = \lim_{u \rightarrow 1^-} [\Phi(\Phi^{-1}(u) + \alpha)]$$

Novamente $\Phi(+\infty) = 1$ e $+\infty + \alpha = +\infty$. Logo:

$$g_\alpha(1) = \Phi(+\infty) = 1$$

- A primeira derivada é:

$$\frac{d(g_\alpha(u))}{du} = \Phi'(\Phi^{-1}(u) + \alpha) \cdot ((\Phi^{-1}(u) + \alpha)')$$

³Vamos utilizar isto, para simplificar a notação dos limites.

Sabemos que:

$$\frac{d(\Phi(x))}{dx} = f(x) \text{ e que } (f^{-1}(x))' = \frac{1}{f'(f^{-1}(x))}$$

Substituindo obtemos:

$$g'_\alpha(u) = \frac{f(x + \alpha)}{f(x)} = \exp\left(\frac{-\alpha x + \alpha^2}{2}\right) > 0$$

É fácil de ver que $g'(0) = +\infty$ utilizando os limites introduzidos no ponto acima.

- A segunda derivada é:

$$\frac{d^2(g_\alpha(u))}{du^2} = \frac{d}{du} \left(\frac{d(g_\alpha(u))}{du} \right) = \frac{-(x + \alpha)f(x + \alpha) + xf(x + \alpha)}{(f(x))^2}$$

Simplificando um pouco obtemos:

$$g''(u) = \frac{-\alpha f(x + \alpha)}{f(x)^2}$$

Ou seja, dependendo do valor de α , a segunda derivada vai ser positiva ou negativa. Escolhendo $\alpha < 0$ obtemos que g_α é concava.

Vamos agora introduzir alguma notação que nos será útil mais a frente. Seja:

$$H[X; \alpha] = \int_{-\infty}^0 g_\alpha(S_X(x)) - 1 \, dx + \int_0^{+\infty} g_\alpha(S_X(x)) \, dx$$

3.2.1 Algumas propriedades da função de Wang

Tal como foi mostrado em [2] temos algumas propriedades para esta função bastante úteis, e que devemos ter sempre em conta.

- $\min[X] \leq H[X; \alpha] \leq \max[X]$.
- $H[X; \alpha]$ é uma função crescente de α . À medida que α aumenta de $-\infty$ para $+\infty$, $H[X; \alpha]$ aumenta de $\min[X]$ para $\max[X]$.
- Para uma constante c , $H[c; \alpha] = c$ e $H[X + c; \alpha] = H[X; \alpha] + c$.
- Para uma variável não constante X , $H[X; \alpha] < E[X]$ se $\alpha < 0$, $H[X; \alpha] = E[X]$ se $\alpha = 0$ e $H[X; \alpha] > E[X]$ se $\alpha > 0$.

- Para $b > 0$, $H[bX; \alpha] = bH[X; \alpha]$.
- Para $b < 0$, temos que $H[bX; \alpha] = bH[X; -\alpha]$. Como caso especial, $H[-X; \alpha] = -H[X; -\alpha]$.
- Se X_1 e X_2 são comonótonas, então $H[X_1 + X_2; \alpha] = H[X_1; \alpha] + H[X_2; \alpha]$. Duas camadas do mesmo risco são comonótonas, e portanto,

$$H[X(a, b); \alpha] + H[X(b, c); \alpha] = H[X(a, c); \alpha], \text{ onde } a < b < c.$$

- Para quaisquer duas variáveis X_1 e X_2 , $H[X_1 + X_2; \alpha] \leq H[X_1; \alpha] + H[X_2; \alpha]$, se $\alpha > 0$ e $H[X_1 + X_2; \alpha] \geq H[X_1; \alpha] + H[X_2; \alpha]$, se $\alpha < 0$. Estas desigualdades indicam o benefício de diversificação, com a ressalva que não existe diversificação entre riscos comonótonos.
- Para o risco Bernoulli (Θ) com $P\{X = 1\} = \Theta$, se $\alpha > 0$,

$$\lim_{\Theta \rightarrow 0} \frac{H[X; \alpha]}{E[X]} = g'_\alpha(0) = +\infty$$

Se o risco X segue uma distribuição $\mathcal{N}(\mu, \sigma^2)$ com uma função de sobrevivência S_X , então $S_{X'} = g[S_X]$ é outra distribuição normal com $\mu' = \mu + \alpha\sigma$ e $\sigma' = \sigma$. Portanto, $H[X; \alpha] = E[X] + \alpha \sigma[X]$. Isso recupera o princípio tradicional do prémio de desvio padrão, onde até o parâmetro α se mantém o mesmo para ambos os métodos.

Se o risco Y com distribuição S_Y segue uma distribuição Log-Normal tal que $\ln(Y) \sim N(\mu, \sigma^2)$, então $S'_Y = g[S_Y]$ é outra distribuição Log-Normal com media $\mu' = \mu + \alpha\sigma$ e desvio-padrão $\sigma' = \sigma$.

3.3 Exemplos

Para clarificar alguns destes conceitos aqui introduzidos, vamos dar 2 exemplos teóricos. Vamos definir duas funções de sobrevivência, bastante comuns na modelação do risco, calcular algumas medidas de risco, como por exemplo a Perda Esperada, que deve ser sempre a primeira coisa a calcular, o risco ajustado ao prémio, também conhecido como princípio do risco ajustado, e a carga relativa. Ou seja, vamos calcular o valor esperado das perdas, o valor esperado das perdas ajustado ao risco pela função de distorção, e ver o aumento relativo da Perda Esperada e do Prémio.

3.3.1 Exemplo 3.1

Vamos considerar seguinte função de sobrevivência, com X a seguir uma distribuição de Pareto:

$$S_X(x) = \left(\frac{2000}{2000 + x} \right)^{1.2}, \text{ com } x > 0$$

Para comparar diferentes camadas vamos assumir que só houve uma apólice. Para ilustrar numericamente, vamos considerar $\alpha = 0.1$. Então, quando aplicamos $H[X; 0.1]$ numa camada em que o limite é 50 000 \$ obtemos uma perda esperada de 4 793 \$ e um prémio ajustado ao risco de 5 487 \$, o que implica uma carga relativa de 14.5%

Em termos comparativos com o *PH-transform* vamos escolher um r tal que a carga relativa seja também de 14.5%, obtemos assim $r = 0.9245$. Vamos agora ver como os mesmos valores se comportam em diferentes camadas.

Camada em 000's	Perda Esperada	Prémio de PH	Carga Relativa %	Prémio de $H[X; \alpha]$	Carga Relativa %
(0, 50]	4,793	5,487	14.5	5,487	14.5
(50, 100]	657	910	38.4	845	28.6
(100, 200]	582	857	47.2	769	32.2
(200, 300]	307	475	54.7	414	34.9
(300, 400]	204	325	59.6	278	36.6
(400, 500]	150	246	63.3	207	37.8
(500, 1000]	428	728	70.1	598	39.9
(1000, 2000]	373	675	81.1	533	43.0
(2000, 5000]	420	819	94.7	616	46.5
(5000, 10000]	271	567	109.5	406	49.9

Tabela 1: Tabela para $\alpha = 0.1$ e $r = 0.9245$

Como podemos observar na Tabela 1, para camadas mais altas o *PH-transform* produz um risco relativo que aumenta muito mais depressa que a função de Wang, este comportamento não é desejado.

3.3.2 Exemplo 3.2

Vamos agora considerar o exemplo hipotético de um lançamento de um satélite. Suponhamos que a distribuição da perda esperada para o lançamento de um

satélite comercial é uma de Bernulli com 5 por cento de probabilidade de uma perda total de 100 milhões de dólares. Este risco é partilhado por uma série de (re)seguradoras em todo o mundo. A distribuição da perda do lançamento do satélite é dada por

$$S_X(x) = \begin{cases} 0.05, & 0 < x < 100 \\ 0, & 100 \leq x \end{cases}$$

Usando o operador de distorção g_α , com $\alpha = 0.1$,

$$g_\alpha[S_X(x)] = \begin{cases} g_\alpha(0.05) = 0.0612, & 0 < x < 100 \\ 0, & 100 \leq x \end{cases}$$

Isto implica um prémio de risco ajustado (excluindo despesas) de 6.12 milhões de dólares ou uma carga de 22.4 %. O grande tamanho do risco pode indicar um risco sistemático maior (devido a uma maior concentração do risco combinado com uma amostra relativamente pequena para estimar). Assim, um α maior pode ser necessário para precificar este risco. Se usarmos um $\alpha = 0.15$, o resultado é um prémio ajustado ao risco de 6.75 milhões de dólares ou uma carga de 35 % (excluindo despesas)

4 Análise de perdas de uma seguradora

Nesta secção vamos analisar um conjunto de dados provenientes das perdas de uma seguradora. Vamos aplicar a função de distorção de Wang e transformar os dados e em seguida, calcular algumas medidas de risco, como por exemplo as perdas esperadas, o prémio ajustado ao risco, a carga relativa. Vamos também introduzir algumas medidas de risco, e avaliar, mas deixamos as explicações mais detalhadas para os trabalhos dos nossos colegas.

VaR, representa a perda com um nível de confiança de α , ou seja temos $1 - \alpha$ de confiança que a perda não vai exceder o valor associado a esse quantil.

CVaR, é muito parecido com o VaR, com a diferença de que considera a media acima do quantil.

De uma forma mais técnica temos:

$$\text{Var}_\alpha = \text{quantil}_{1-\alpha}(X)$$

$$\text{CVar}_\alpha = E[X \mid \text{Var}_\alpha \leq X]$$

Vamos ainda introduzir o conceito de desvio de cauda à direita e o desvio de cauda à esquerda, que vai servir apenas para classificar as caudas das nossas distribuições em comparação com a distribuição normal. Tendo sido introduzido este conceito em [3] para uma *PH-transform* com $r = 0.5$ e generalizado em [4]. Seja então:

$$\begin{aligned} \text{RD}_\alpha[X] &= \frac{H[X; \alpha] - E[X]}{\alpha} \\ \text{LD}_\alpha[X] &= \frac{E[X] - H[X; \alpha]}{\alpha} \end{aligned}$$

Definimos então o índice da cauda à direita e o índice da cauda à esquerda como:

$$\begin{aligned} \text{RTI}_\alpha[X] &= \text{RD}_{2\alpha}[X] / \text{RD}_\alpha[X] \\ \text{LTI}_\alpha[X] &= \text{LD}_{2\alpha}[X] / \text{LD}_\alpha[X] \end{aligned}$$

Para algum α positivo.

A distribuição normal apresenta um $\text{RTI}_\alpha[X]$ bem como um $\text{LTI}_\alpha[X]$ de 1. Conseguimos ver que, se o índice for maior que 1, indica que a cauda é mais pesada do que a da normal e se for menor do que 1, indica que a cauda é mais leve que a normal.

4.1 Análise de Dados e Transformação de Wang

Como já foi referido, vamos aplicar a transformação de Wang a um conjunto de dados de uma seguradora.

Primeiro vamos ver os dados:




Figura 1: Histograma da frequência das perdas




Figura 2: Boxplot das perdas

Através da análise do histograma, podemos quase com certeza dizer que os dados provêm de uma distribuição de Pareto, assim como a partir do box-plot também conseguimos concluir que a presença de outliers é muito forte, ou seja é bastante provável que aconteçam perdas significativas.

De seguida, criamos um código no R e aplicamos a transformação de Wang com um $\alpha = 0.36353419$. A escolha deste valor vai fazer sentido na escolha a subsecção a seguir. Apresentamos de seguida as Funções de Sobrevivência, a azul dos dados originais, e a vermelho depois de aplicada a função de distorção. Podemos observar que a área da função aumentou, o que é justificado pelo parâmetro $\alpha > 0$, que representa uma aversão ao risco. Ou seja estamos a dar ênfase a valores mais extremos.




Figura 3: Funções de Sobrevivência

4.2 Análise de Resultados

No mesmo código do R, calculamos alguns valores que nos ajudam a perceber o risco associado a este conjunto de dados. Começamos, como é óbvio, pela perda esperada e prémio ajustado ao risco $H[X; \alpha]$ para o α referido, e de seguida a carga relativa.

Obtemos assim uma perda esperada de 15129.12 \$ e um prémio ajustado ao risco de 18155.96 \$, bem como uma carga relativa de 20%. Outro fator que

calculamos foi o $RTI_\alpha[X]$, para o qual obtivemos o valor de 1.1. A escolha do α teve por base fazer com que a carga relativa fosse 20%, o que é razoável, dado que a cauda das perdas depois de transformadas não vai diferir muito de uma cauda de uma distribuição normal.

De seguida, fomos calcular o $VaR_{0.95}$ e $CVaR_{0.95}$ antes de aplicar a transformação, e depois da transformação, obtendo os seguintes valores:

	Original	Transformado
$VaR_{0.95}$	30363.54 \$	36406.99 \$
$CVaR_{0.95}$	38299.18 \$	44909.15 \$

Tabela 2: Tabela dos valores do Var e do CVaR, antes e depois da transformação.

Neste caso, do mundo real, tratamos de cerca de 100 000 perdas de uma empresa. Analisamos também os valores do VaR_α e do $CVaR_\alpha$ e como um α muda de forma impactante estes valores. Outro factor de relevo na modelação destes eventos é a significância das caudas, principalmente a cauda direita, dado que estamos na maior parte do tempo a trabalhar com valores não negativos, que são algo que alguém apenas da área da estatística possa desconsiderar, para nos não, daí a necessidade de introduzir algo que as possa avaliar.

5 Conclusão

Neste trabalho, analisamos diversas medidas de risco e avaliamos o impacto da aplicação da função de distorção de Wang, que apesar de não avaliar em concreto o risco, permite incorporar uma dimensão mais realista ao processo de modelagem. Através da sua aplicação, foi possível compreender como o medo de perdas inesperadas influencia a percepção e o comportamento em relação ao risco, oferecendo uma abordagem mais alinhada com cenários reais de tomada de decisão.

A função de Wang mostrou-se eficaz para ajustar as medidas tradicionais de risco, adicionando uma perspetiva comportamental que reflete melhor a aversão natural às perdas extremas. Este ajuste é essencial para modelar situações onde as consequências de eventos inesperados têm um impacto desproporcional na tomada de decisão, como é frequente em ambientes financeiros.

Desta forma, o trabalho encerra destacando o valor da função de Wang como uma contribuição significativa para a gestão de riscos, especialmente em contextos onde a compreensão e mitigação de perdas inesperadas são fatores críticos para a tomada de decisão informada e eficaz.

Lista de Tabelas

1	Tabela para $\alpha = 0.1$ e $r = 0.9245$	10
2	Tabela dos valores do Var e do CVaR, antes e depois da transformação.	15

Lista de Figuras

1	Histograma da frequência das perdas	13
2	Boxplot das perdas	13
3	Funções de Sobrevivência	14

Referências

- [1] Shaun Wang. Insurance pricing and increased limits ratemaking by proportional hazards transforms. *Insurance: Mathematics and Economics*, 17(1):43–54, 1995.
- [2] Shaun Wang. Premium calculation by transforming the layer premium density. *ASTIN Bulletin: The Journal of the IAA*, 26(1):71–92, 1996.
- [3] Shaun Wang. An actuarial index of the right-tail risk. *North American Actuarial Journal*, 2(2):88–101, 1998.
- [4] Shaun S Wang. A class of distortion operators for pricing financial and insurance risks. *Journal of risk and insurance*, pages 15–36, 2000.